AUTHEN 消费者端鉴真系统
140 条真实算法/API 批测报告

QA-140 合并复算与首页变更证据包

2026 年 10 月 20 日

摘要

结论先行：本报告合并 shard_01（前 70 条）与 shard_02（后 70 条）两份真实批测明细，共 **140 条**，全部实际发出 HTTP 请求并留存原始请求/响应。**140 条 HTTP 状态均为 200，但 HTTP 200 不等于通过**；按「APP 实际五类判定与参考标签五类完全一致」的严格口径复算，**严格通过 17 条，未通过 123 条，严格通过率 12.14%**。本批为**算法/API 流程批测**，浏览器 RPA 仅对首页三张场景卡做一次性冒烟，不参与 140 条结果；本批只验证现有规则/API 是否正确执行，**专业鉴伪能力（AI 生成检测、视频逐帧篡改、音频合成鉴定、专业功效核验）尚未全部接入，未在本批验证**。

目录

1 测试范围与数据口径 **3**

1.1 被测对象与调用入口 3

1.2 数据包与参考标签 3

1.3 五类判定与严格通过定义 3

1.4 批测与冒烟的边界（重要） 3

2 总体结果 **4**

3 期望判定与实际判定分布 **4**

4 混淆矩阵：期望行 × 实际列 **4**

5 分模态统计 **4**

6 分场景（split）统计 **5**

7 失败分布 **5**

8 典型案例（可回溯至 footprint） **5**

9 限制与能力边界 **5**

9.1 本批验证了什么 5

9.2 未接入/未验证（不得宣称已具备） 5
9.3 测试预处理局限 6

10 消费者首页修改说明与前后证据 **7**
10.1 改动范围 7
10.2 改动验证 7
10.3 首页前后对比 8

11 复现指南与交付清单 **8**
11.1 复现步骤 8
11.2 交付文件清单（根目录 QA-140-report/） 8

1 测试范围与数据口径

1.1 被测对象与调用入口

被测对象为本地消费者端网页 APP（源码 `AUTHEN/web/`，企业端未启用、未改动）。140 条全部真实调用同源服务端 `web/server.mjs` 的 `POST /api/review`（pipeline `inspect`，multi-agent-6dim-v2）；音频/视频先经同实例 `POST /api/transcribe`（faster-whisper small）转写再送鉴真。shard_01 实例端口 4191，shard_02 实例端口 4192，均为本地独立进程。

1.2 数据包与参考标签

- 数据包:`AUTHEN_` 多模态测试数据包 `_v2_140` 条(构造/脱敏验收集,`manifest_labels.jsonl` 共 140 条参考标签)。- 参考标签为**构造样本的人工标注，非第三方真值**，结果不得表述为真实平台准确率;答案(annotations、manifest_labels)未进入任何模型请求。- 合并时已用 `manifest_labels.jsonl` 对每条记录的期望判定、模态、场景做独立交叉校验，0 条不一致。

1.3 五类判定与严格通过定义

APP 总判定限定五类：**暂未发现问题 / 有明确问题 / 线索级（待核验）/ 资料不足 / 无法判定**。

- **严格通过**：APP 实际五类判定 == 参考标签期望五类，逐字完全一致。
- **HTTP 200 / API 成功只表示流程跑通**（服务在线、请求被解析、返回 JSON），**不得计为通过**；本批 140 条全部 200，与通过数 17 条形成明确对照。
- error_type:`none`(一致)/ `verdict_mismatch`(五类不一致);本批无 http_error、pipeline_failed、transport_error。
- mismatch_kind：`missed_conflict`（漏报明确问题）、`false_alarm_or_clue`（干净样本误报/提前给线索）、`other`（其他不一致）。

1.4 批测与冒烟的边界（重要）

- 140 条均为**算法/API 批测**：脚本按前端真实提交格式构造请求，逐条发送并落盘原始请求/响应/日志。
- **浏览器 RPA 只对首页三张场景卡（种草内容 / 评论区 / 图片视频音频）做一次性冒烟**，验证弹窗预选、引导条与选文件触发可用；RPA 结果不计入 140 条通过统计。
- 本批区分「现有规则/API 是否正确执行」与「专业鉴伪能力是否验证」：后者尚未全部接入，不得据本批结果宣称具备专业鉴伪能力。

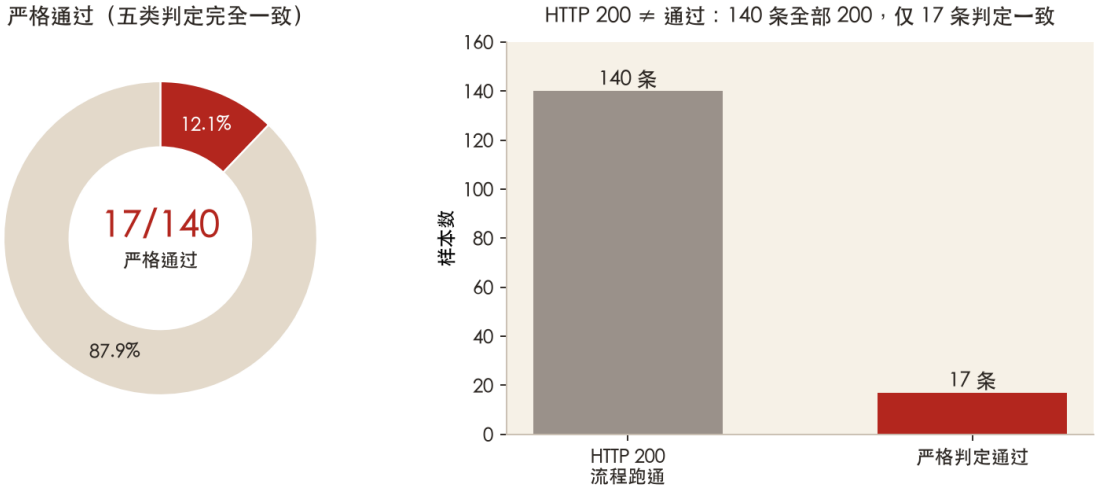


图 1: 严格通过概览：140 条全部 HTTP 200，仅 17 条五类判定一致（12.14%）

批次	样本数	严格通过	未通过	严格通过率
shard_01（前 70：音频/评论/图文/文章/图片）	70	13	57	18.57%
shard_02（后 70：图片/图文/文章/视频/转发变体）	70	4	66	5.71%
合计	**140**	**17**	**123**	**12.14%**

2 总体结果

3 期望判定与实际判定分布

观察：APP 实际输出高度集中在「线索级（待核验）62」与「资料不足 74」，未输出「暂未发现问题」与「无法判定」；对期望「有明确问题」与「暂未发现问题」的两端样本普遍向中间降级，呈现保守的「线索/资料不足」倾向。

4 混淆矩阵：期望行 × 实际列

对角合计：$3 + 2 + 12 = 17$。主要错向：期望「暂未发现问题」54 条中 23 条被给线索、31 条判资料不足；期望「有明确问题」53 条中 28 条降级为线索、22 条降级为资料不足，仅 3 条命中。

5 分模态统计

评论组通过率最高（6/24，多为「资料不足」命中）；视频（12）与转发变体（8）零通过。需注意：多数「通过」集中在双方都判「资料不足」的保守情形，不等于鉴伪能力正确。

流程指标	数量	说明
HTTP 200	140	全部流程跑通，不等于判定通过
verdict_mismatch	123	五类判定不一致
none（一致）	17	严格通过
非 200 / 传输失败 / 流水线失败	0	无

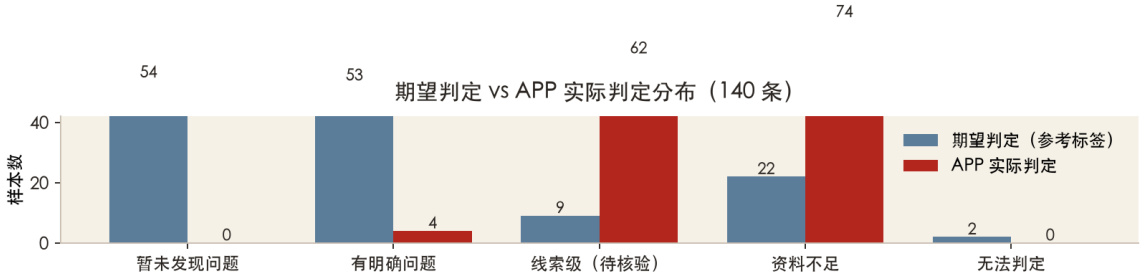


图 2: 期望判定（蓝）与 APP 实际判定（红）分布对比

6 分场景（split）统计

7 失败分布

失败以**漏报为主**（50 条）：现有规则链倾向给「线索级/资料不足」，不敢落到「有明确问题」；其次为误报/提前给线索（25 条）。

8 典型案例（可回溯至 footprint）

全部 17 条通过样本：A010、C002、C006、C008、C010、C011、E106、E111、E118、E127、E131、E135、E137、M002、M004、M016、T018。逐条原始请求/响应见 `footprint/samples/`，未通过清单见 `data/failures_123.json`。

9 限制与能力边界

9.1 本批验证了什么

现有规则/API 的**流程正确性**：D1 数字/事实冲突（公开资料 +LLM 对照）、D5 绝对化/越界功效/权威背书、D3 图文数字对照、D2 本地图像软取证（copy-move/ELA/频谱/噪声/元数据，pillow/opencv）、评论重复与模式线索；请求解析、转写、OCR 并入、限流重试、响应结构均正常（140/140 HTTP 200，0 传输错误）。

9.2 未接入/未验证（不得宣称已具备）

- AI 生成图检测（UFD）：`torch=false / open_clip=false / ufd_dir=""`，未启用。
- 视频逐帧与画面篡改鉴定：仅抽帧 OCR 字幕与口播转写，未做帧级篡改定位。

五类判定	期望分布	实际分布	差值（实际 − 期望）
暂未发现问题	54	0	−54
有明确问题	53	4	−49
线索级（待核验）	9	62	+53
资料不足	22	74	+52
无法判定	2	0	−2

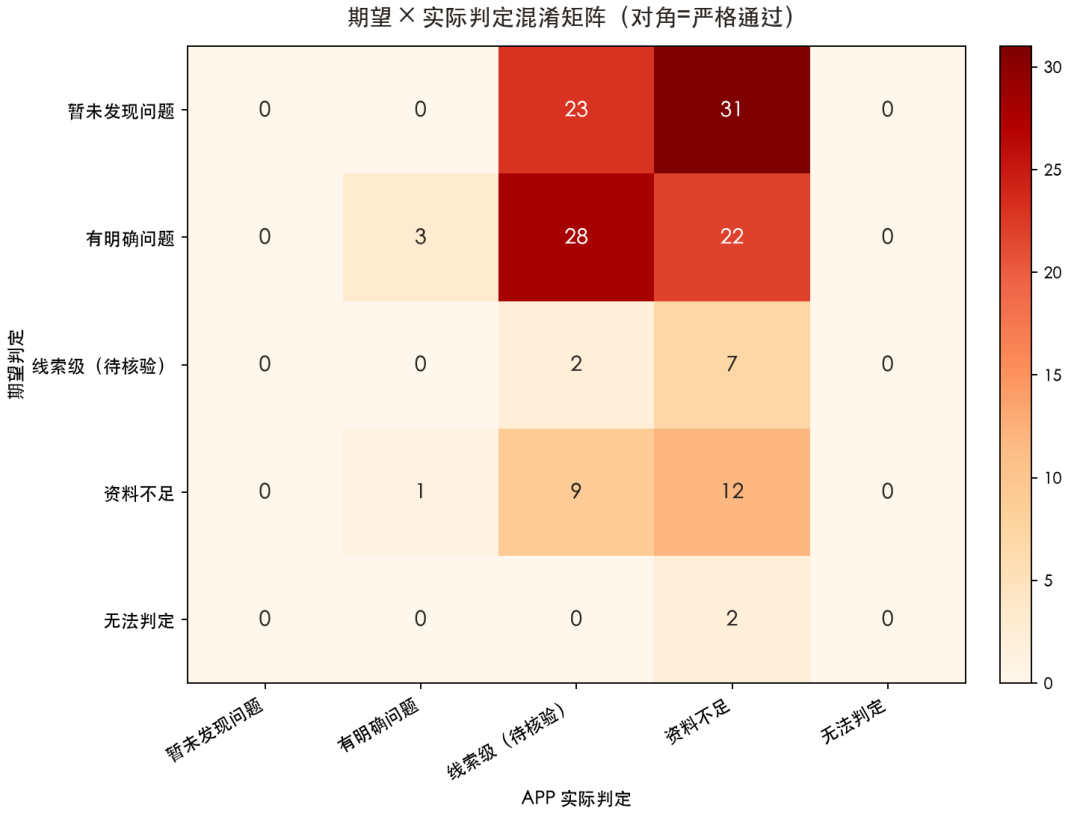


图 3: 期望 × 实际判定混淆矩阵，对角元素之和为严格通过数 17

- 音频合成/声音克隆检测：音频为合成口播转写，APP 不判断声音是否合成。
- 专业医学/化妆品功效核验：APP 内置知识库不含本包虚构「岑予」产品资料，D1 公开对照多为空，故大量落「资料不足」。
- 像素级篡改定位、官方品牌资料库未接入。

9.3 测试预处理局限

- 本地 OCR 用 tesseract（chi_sim+eng），对花体/压缩图识别有限，可能影响 D3 图文数字比对；这是测试预处理局限，不等同 APP 结论。- shard_01 未记录逐条耗时（app_elapsed_ms=0）；shard_02 有耗时记录的 116 条中位数约 1.9s，个别重试样本耗时较长（限流退避），耗时不作为质量指标。- 参考标签为构造标注，样本量 140，结论仅适用于本验收集。

期望 \实际	暂未发现问题	有明确问题	线索级	资料不足	无法判定
暂未发现问题	0	0	23	31	0
有明确问题	0	**3**	28	22	0
线索级（待核验）	0	0	**2**	7	0
资料不足	0	1	9	**12**	0
无法判定	0	0	0	2	0

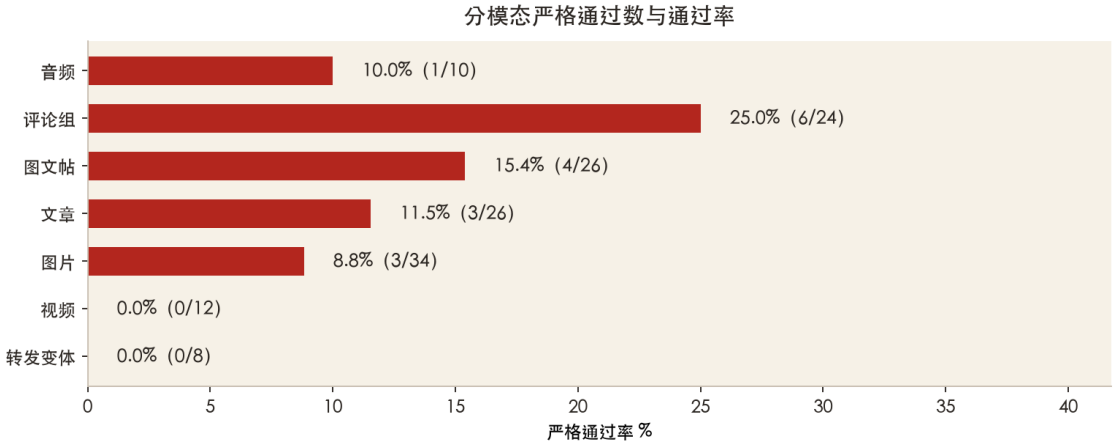


图 4: 分模态严格通过数与通过率（括号内为通过/总数）

10　消费者首页修改说明与前后证据

10.1　改动范围

仅改动消费者网页首页（百宝箱/Toolbox），企业管理端、线上发布、原生 iOS、服务端 pipeline 均未改动。在保留原有视觉（奶油色纸底、哑光黑字、口红红、402×874 手机比例）与原有「发来看看」流程前提下，hero 下方新增「从哪里发来？」三张场景卡，点击统一汇入现有 smart 弹窗（SmartIntake，标题「发来看看」）：

- **种草内容**：预选重点「功效靠谱吗?」，粉色引导条，贴笔记/商品链接连同功效承诺核对。
- **评论区**：预选重点「好评真实吗?」，薄荷色引导条，读公开好评或直接贴评论。
- **图片/视频/音频**：米色引导条，250ms 后自动触发系统选文件；不弹时可点「放入素材」。

改动文件 4 个：`pages.tsx`（场景区）、`store.tsx`（intakePreset 状态）、`SmartIntake.tsx`（预选/引导条/自动选文件）、`app.css`（场景样式与窄屏收紧）。变更包、统一 diff 与原件备份均在 `homepage/source/` 与 `homepage/before/src/`（详见第十一节清单）。

10.2　改动验证

- `npm test`：120 项全部通过（编辑前/后各一次，日志 `homepage/logs/`）。
- `npm run build`：tsc + vite 构建成功（1642 模块，1.50s，仅既有 chunk 体积提示）。
- 裸根路径 `/` 与 `/authen/` 返回 200 并完整渲染，控制台 0 报错/警告；页面横向溢出 0。

模态	样本数	严格通过	未通过	严格通过率
音频	10	1	9	10.0%
评论组	24	6	18	25.0%
图文帖	26	4	22	15.4%
文章	26	3	23	11.5%
图片	34	3	31	8.8%
视频	12	0	12	0.0%
转发变体	8	0	8	0.0%

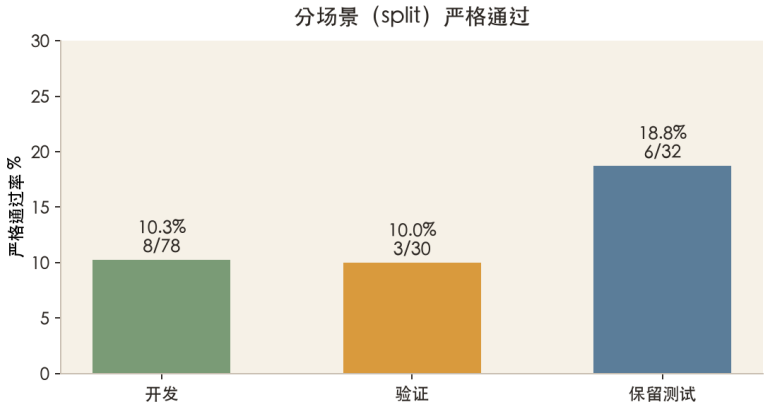


图 5: 分场景严格通过

10.3 首页前后对比

11 复现指南与交付清单

11.1 复现步骤

1. 启动本地消费者端后端（shard_02 改用独立端口 4192），命令见各分片 RUNBOOK。
2. 按分片 RUNBOOK（已留存于足迹 batch_logs）执行批次脚本。
3. 运行合并复算脚本生成汇总；统计以 `summary_140.json` 为准，脚本见 `scripts/`。

11.2 交付文件清单（根目录 QA-140-report/）

- `data/merged_140.jsonl`：140 条合并明细（结构化全字段）。
- `data/merged_140.csv`：140 条扁平表（UTF-8-BOM）。
- `data/summary_140.json`：独立复算汇总（通过数、多维分布、混淆矩阵、失败类型、源文件 sha256）。
- `data/failures_123.json`：123 条未通过清单。
- `footprint/`：逐样本 request/response/run.log + 批次日志/脚本/运行说明 + index.csv。
- `figures/`：7 张统计图表 PNG。

场景	样本数	严格通过	通过率
开发	78	8	10.26%
验证	30	3	10.00%
保留测试	32	6	18.75%

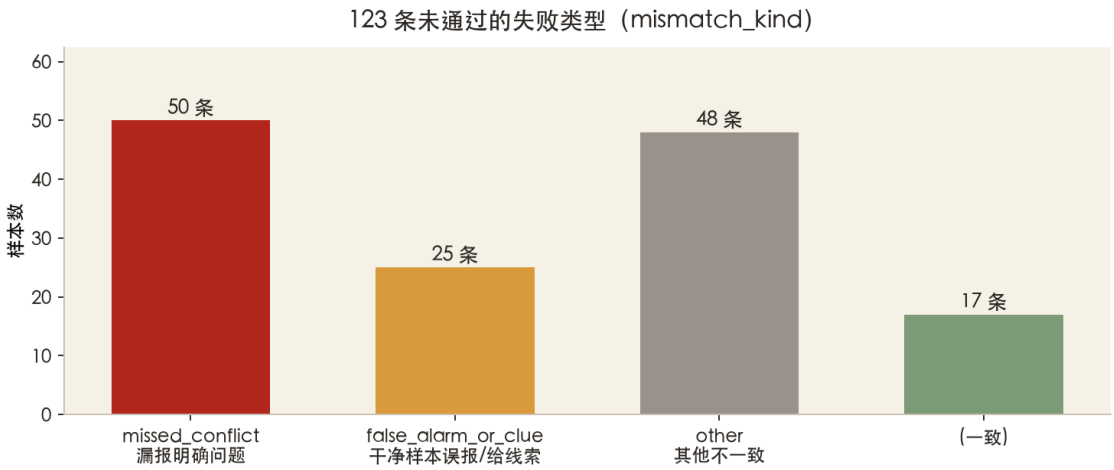


图 6: 123 条未通过的失败类型分布

- `homepage/`：修改说明、前后截图、源码变更包 zip、统一 diff、测试/构建日志。
- `report/report.tex` 与 `report/report.pdf`：本报告源码与实际编译 PDF。
- `scripts/`：合并复算、足迹组装、出图脚本（可重跑）。

mismatch_kind	数量	含义
missed_conflict（漏报明确问题）	50	期望「有明确问题」被降级为线索/资料不足
false_alarm_or_clue（误报/给线索）	25	干净或资料不足样本被提前给线索/明确问题
other（其他不一致）	48	其余类别错配（含资料不足 ↔ 线索等）
（一致，严格通过）	17	—

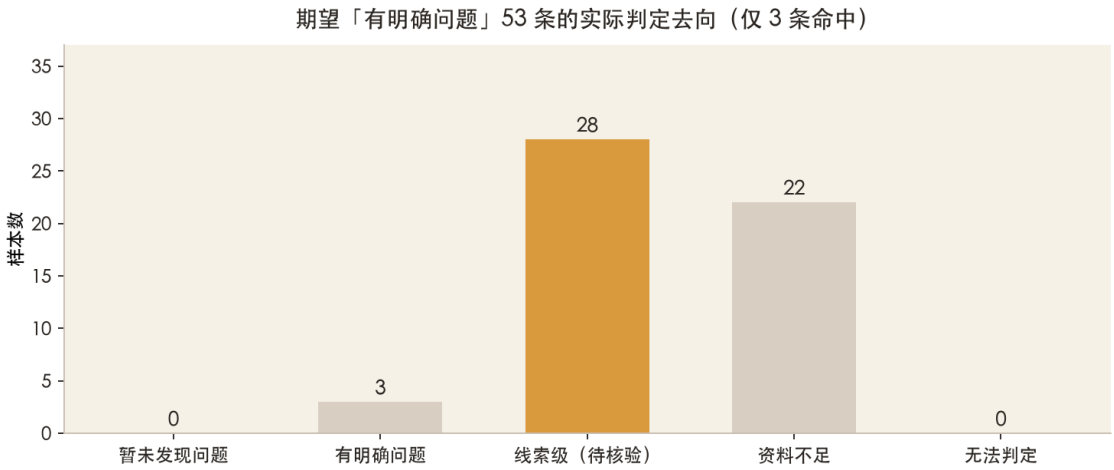
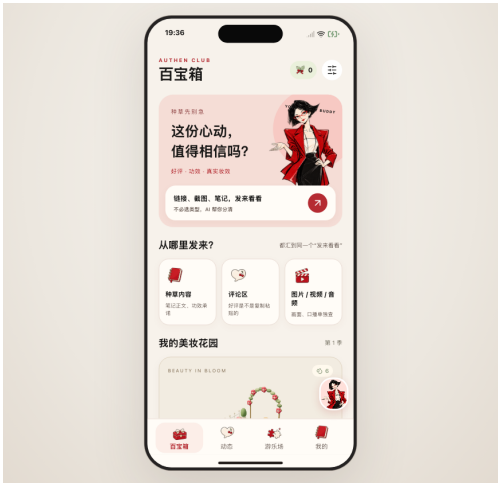


图 7: 期望「有明确问题」53 条的实际去向：仅 3 条命中，28 条降级为线索、22 条降级为资料不足

样本	期望	实际	类型	标签事实 / APP 输出摘要（留痕见 footprint/samples/）
A002	有明确问题	资料不足	漏报	口播人数/观察时间/测量项目/结果均被替换；APP：「缺能对照的公开资料，暂时判断不了。」
V006	有明确问题	线索级	漏报	第二段字幕与口播、资料不符；APP 仅报画面重复线索，未落到明确问题。
X003	有明确问题	线索级	漏报	局部痕迹移除（jpeg_low）；APP 仅描述表面纹理，判待核验。
I009	暂未发现问题	线索级	误报	图片文字与资料一致；APP 因画面两块内容吻合给「待核验」线索。
V007	暂未发现问题	线索级	误报	字幕/口播/资料一致；APP 仅给画面重复线索。
M018	资料不足	有明确问题	误报	无测试来源无法支撑「覆盖所有人」；APP 直接落「有明确问题」，较期望更激进。
M002	有明确问题	有明确问题	通过	人数/时间/结果被替换，APP 检出与资料原文对不上，命中。
A010	资料不足	资料不足	通过	无可对照公开资料，双方均判资料不足（保守一致）。
E137	线索级	线索级	通过	同一「七天见效」跨文章/图/评论重复且属同一血缘，双方均给线索级。



修改前：hero 下方直接进入「我的美妆花园」，无场景入口



修改后：hero 下方新增「从哪里发来?」三张场景卡



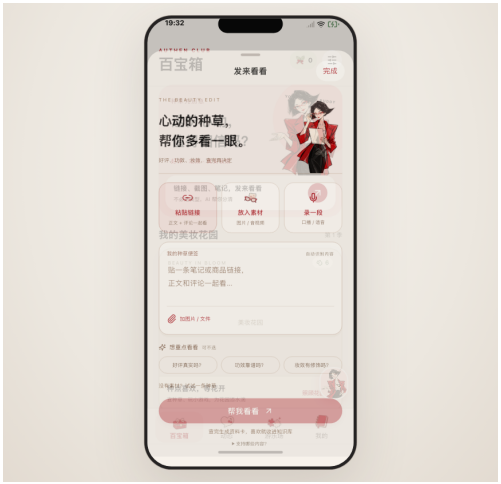
种草内容场景



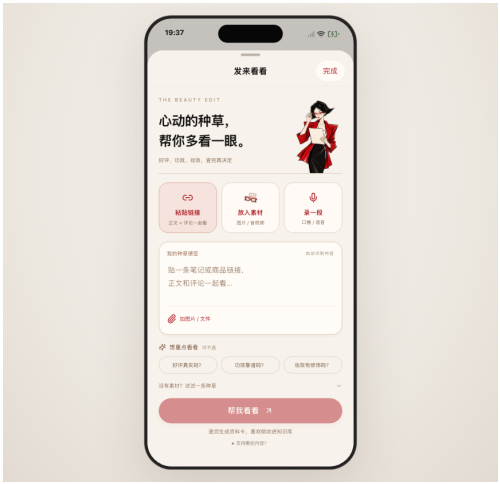
评论区场景



图片/视频/音频场景



修改前原「发来看看」弹窗



hero 主入口回归：无场景引导条，原流程不变