AUTHEN 鉴真流水线 v2.1
从 12% 到 57%：取证层重建与实测报告

消费者端 APP · 赛题 2

2026 年 10 月 20 日

数据集：AUTHEN_ 多模态测试数据包 _v2_140 条（构造/脱敏验收集）

1 结论先行

上一版在 140 条验收集上严格通过 17 条（12.14%）。本轮重建取证层后，同一批数据、同一套五类口径，**严格通过 80 条（57.14%）**，提升 45.0 个百分点。视频类从 0/12 做到 12/12，音频从 1/10 到 8/10，图片从 3/34 到 16/34。

没有达到 90%。这一点必须先讲清楚：剩余 60 条失败集中在三类需要逐案语义判断的样本上，靠通用规则改不动，必须补专用规则或接模型，见第五节。本文只报实测数字，不报推测数字。

2 归因：问题不在编排，也不在融合规则

用已记录的 140 条六维证据做反推实验：假设判定规则完全正确，仅按六维证据态映射五类，上限是多少。

映射方案	严格通过
现行规则（任一维 EI 即判资料不足）	17/140（12.1%）
E3→ 明确，E2/E1→ 线索，E0→ 暂无	18/140（12.9%）
E3/E2→ 明确，E1→ 线索，E0→ 暂无	30/140（21.4%）
用标签六维适用面 + E2→ 明确	27/140（19.3%）

把规则改到最优也只有 21%，说明病灶在证据层。140 条全部 HTTP 200、零传输错误、耗时正常，编排本身是通的。证据库存显示：期望「暂未发现问题」的 54 条里，26 条零证据、19 条被误报成两项证据、只有 2 条拿到核对无误；期望「有明确问题」的 53 条里，19 条零证据、19 条只到线索、只有 3 条拿到直接冲突。

四条结构性缺陷，逐条对应样本：

1. **资料从未进入流水线。**132 条自带 reference_files（K 资料卡 84、C 案例卡 35），但接口没有接收字段，服务端的 `provided` 参数被忽略，只能退回本地知识库，批测时零命中。文字依据这一维因此恒为材料不足。标本是 E101：来源卡否认该专家身份，系统只说「提到了专家但没给出处」，退成线索级。

2. **适用矩阵按模态写死。**音频强判画面、评论六到九条就判样本太少，叠加「任一维材料不足即整体资料不足」，5 条干净音频、12 条干净评论从结构上不可能通过。
3. **E2 一律降级。**画面、评论、上下文三维全被划成模式型，证据出在这三维最高只能到线索级，图片篡改、字幕篡改、评论事实冲突三类「有明确问题」不可达。
4. **没有路径产出「无法判定」。**工具失败被当成材料不足，两条期望无法判定的样本落进资料不足。

算法层另有两个真误报：合成排版图上的复制粘贴检测在重复版式上误触发（22 条干净样本拿到画面信号，与篡改样本呈负相关）；视觉模型把图上自带的「教学改编／脱敏合成」水印当成可疑线索。

3 这一轮改了什么

3.1 新增主张—资料对照引擎

新模块 `pipeline/grounding.mjs`，纯确定性，不调模型。把材料按句切开，与资料卡逐句对照，输出一致、冲突、沉默三种结果，每条都带材料原句与资料原句。判冲突的规则有五类：同一属性数字不同；绝对化承诺而资料对同一话题有边界说明；医疗级功效而资料写明未做该类试验；权威背书被资料否认；否定式说法与资料相反（材料写「完全无香精」，资料写含香精）。另有两条反向规则：材料自己写出的免责说明不算冲突；「原来写 10%，实际是 2%」这类纠正语境算一致。

一句主张是否算「同一话题」用字符二元组重合度衡量（阈值 0.24 至 0.28），词面高度重合（ 0.5）时判一致——这条兜底规则让大量同义改写的干净文本从材料不足翻成核对无误。

3.2 适用矩阵改为按材料判定

音频不再评画面；评论只评评论区与上下文；图片有文字才评文字依据；视频没有逐帧时画面降为可选。更关键的是取消了一票否决：只有**必选维度**材料不足才降「资料不足」，可选维度缺材料只写进限制说明。

3.3 取证口径：跑过没信号就是未见异常

检查确实执行过、四项检测都没有信号时，记「未发现被改动痕迹」并附范围限制，不再记材料不足。这是 54 条干净样本能否通过的关键。同时给复制粘贴加了版式闸门：图上有成段可读文字时，重复块按版式元素处理，不计为篡改证据。合成图误报由此从 22 条降到个位数。

3.4 E2 分型重写

能指到一句话、一个数字、一个时间点、一处坐标的，算确证型，可判「有明确问题」；只有风格、模板、行为习惯这类没有落点的，算模式型，最高线索级。硬编码一张「可确证类型」白名单：冲突、数字、时间线、权威、医疗、绝对化、复制粘贴定位。

3.5 第二轮：把资料的元信息剔除干净

第一轮跑完后，90 条干净样本里有相当一部分是靠「版本：2026-10-15」这类资料头信息被判成一致的——对照引擎把元信息行当成了事实句。第二轮把产品、版本、用途、净含量、编号这几类行整行剔除，并要求一致判定至少命中八个字以上。同一批还补了三条规则：材料自己写了「没有做这类试验」时，同一话题的正面说法不再算冲突；一句话里同时出现同一属性的两个值，视为对照或纠正而非宣称；材料说「完全无香精」而资料成分表里列了香精，按成分表判相反。

这一轮净增 1 条：资料不足类回收了 4 条，但图表类的误判同时增加了 3 条，两边基本抵消。这说明在这个数据包上，通用规则的边际收益已经很低。

3.6 评论看时间线，不看条数

新增三条：同一 comment_id 重复是抓取重试，去重后不判问题；有评论说「连续用了 30 天」而首末评论只隔 2 天，判时间线冲突；有相似表达但整批没有发布时间，判无法判定。删掉了「少于十条即材料不足」的门槛。

4 实测结果

维度	改造前	改造后	变化
总体	17/140（12.1%）	80/140（57.1%）	+45.0pt
开发（78）	8	49	+41
验证（30）	3	18	+15
保留测试（32）	6	13	+7
视频	0/12	12/12	+12
音频	1/10	8/10	+7
文章	3/26	16/26	+13
图文帖	4/26	13/26	+9
图片	3/34	16/34	+13
评论组	6/24	13/24	+7
转发变体	0/8	2/8	+2

六个分片都涨，说明改进不是只对某一类样本过拟合。保留测试片只涨 7 条，明显低于开发片的 41 条，提示规则在开发片上有调参成分，这个差距必须如实写进结论。

5 为什么还没到 90%

剩余 60 条按成因分五簇，每簇的失败机制不同：

簇	条数	机制
I 系列图片（来源辨别）	14	标签判定依据是「这张图是不是 AI 生成」，需要生成图检测模型或来源记录；现有像素取证与标签几乎不相关，信号强的是干净图，信号弱的是篡改图
评论语义线索	12	模板改写、关系图、身份关系、主观无据，需要账号历史、关系图或语义相似度，现有规则只到字面重复
转发变体	6	需要与所附原图逐像素比对，数据包未提供配对原图；或需要转码前后字幕比对
图文帖语义冲突	11	图文含义冲突、血缘去重、引用错配，需要读懂图与文的对应关系，不是词面对照能覆盖
图片延伸事实核验	11	订单评论关系、重复图片匹配、对比条件一致性，需要图库与结构化字段

一句话：能靠「说法对资料」解决的部分已经做完，剩下的要么要专用检测模型，要么要结构化数据（账号、时间、图库、配对原图），不是规则能凭空造出来的。

继续硬调规则有两个风险：一是把规则写成标注口径的复述，分数上去但泛化归零；二是误报上升，把干净内容判成有问题，这比漏报更伤消费者信任。因此本轮到此为止，不用继续调参的方式硬凑 90%。

6 已规划的技术路线：离线推理与缓存查表

这一节写的不是已经上线的能力，而是已经设计完成、接口已预留、只差模型权重与少量标注就能落地的路线。之所以单独成节，是因为它决定了这个产品下一阶段的天花板，也解释了为什么不靠继续调规则去凑分数。

6.1 先说不做什么：不在业务服务器上跑大模型

线上业务跑在一台 2 核、物理内存 1967MB 的云主机上，实测可用内存 830MB、swap 4G 已用 1.7G、无 GPU。UniversalFakeDetect 的底座是 CLIP ViT-L/14，fp32 权重 1.7GB，加载加推理峰值约 2.2GB，超过整机物理内存。硬上的结果只有两个：被 OOM 终止，或者把 swap 打满，2 核机器上 swap 抖动会让同机的其它三个站点一起不可用。

所以这条路线的第一个判断是：**模型推理与在线请求解耦**。不在请求链路里跑模型，而是离线算、在线查。

6.2 架构：离线推理 + 按图片哈希查表

离线侧在本地或临时 GPU 实例上批量推理，对每张图片计算三组结果：生成图痕迹分数、图库复用匹配（最近邻与相似度）、图内文字与版式特征。结果按图片内容哈希（SHA-256）索引，写成一份只读的 JSON 缓存，随版本发布一起上线。

在线侧只做一次哈希计算和一次查表：命中就取分数，未命中就如实返回「这张图还没做过专项检测」。运行时内存增量接近零，延迟是毫秒级，2 核 1.2GB 的现有配置完全够用，也不需要改动服务器规格。

这个设计的代价是缓存命中率：同一张图被二次上传能命中，换图、裁切、加滤镜后哈希就变了。因此缓存里同时存一份感知哈希（pHash）与 SSCD 向量，命中不了精确哈希时退到近似匹配，再不行才走「未检测」分支。这一点必须在用户端说清楚，不能让用户以为每张图都做过专项检测。

6.3 三个模块与各自的落地条件

生成图检测用 UniversalFakeDetect：CLIP ViT-L/14 冻结主干提特征，接一个线性分类头。它的好处正好匹配我们的处境——主干不动，只训一个线性头，**几百张标注就能校准**，不需要大规模训练，也不需要 GPU 集群。适配器已经在 `pipeline/forensics.mjs` 里写好，权重缺失时如实返回 not_installed，不会假装跑过。

图库复用匹配用 SSCD 提向量，配合本地图库做最近邻。它解决的是「三个账号用近似同图，声称各自的自拍体验」这类问题，也就是现有规则完全够不着的那一类。落地条件是先有一个基准图库：五百到两千张美妆图，外加一批已知重复对用于校准阈值。

评论关系图不需要模型。数据包里已有账号、发布时间、父评论、点赞四个字段，可以算同号多评、互赞闭环、同话术共现、时间聚集四类结构指标。这条在现有 2 核机器上就能跑，是本路线里唯一可以立刻做、零算力成本的部分。

6.4 小样本校准，而不是重新训练

三个模块里只有生成图检测需要「训练」，而这个训练是线性探针级别：冻结 CLIP 主干，取图像特征，训一个逻辑回归头并校准阈值。一百到三百张标注、单卡几分钟、CPU 十几分钟就能完成一轮。这也是我们敢说「路线已经规划好」的依据——它不是要重训一个多模态大模型，而是把已有的开源表征接上我们自己的判定口径。

校准集的构成比数量更重要：必须同时包含真实拍摄、AI 生成、AI 生成后二次编辑、截图重存四类，且四类都要有美妆场景（试色、包装、上脸、对比图）。只有真实与生成两类的校准集，阈值会在截图和压缩图上失效。

6.5 预期收益与验收方式

按当前 60 条失败的构成估算：生成图检测可回收 8 至 10 条（I 系列来源辨别），图库复用可回收 4 至 6 条，关系图可回收 4 至 6 条，合计把严格通过率推到 78% 至 85%。剩下的差额在「图文含义冲突」这一类，需要多模态模型逐案判断，属于下一阶段的成本。

验收仍然按 140 条、按开发／验证／保留测试三片分别报数，并且同时报「接入前 57.1%」与「接入后」的差。校准集与验收集必须分开，否则线性头会记住验收样本，报出来的数字没有意义。

6.6 这条路线的前提与风险

三个前提必须同时成立：权重许可允许内部测试与演示使用；图库图片有可登记的来源与授权；校准集能覆盖四类来源。缺任何一条，对应模块就只能停在「接口预留」状态，不能对外宣称具备该能力。

风险也要写明：生成图检测对二次压缩、截图重存、局部重绘的敏感性仍然有限，误报会集中在「真实照片被压过多次」的情况；SSCD 只能查已建库的图，查不到不代表没被复用。这两点在用户端都要以「本次检查范围」的形式呈现，不能简化成一句「已鉴定」。

7 尚未完成的部分（按收益排序）

1. **接生成图检测（预计 +8 至 +10）**：UniversalFakeDetect 适配器已写好，只差 torch 与权重；服务器 2 核 1.2G 跑不动，需要 GPU 或按需批处理。
2. **接图片查重与图库（预计 +4 至 +6）**：SSCD 特征 + 本地图库，解决「同图多号」「重复图片匹配」。
3. **结构化评论字段（预计 +4 至 +6）**：账号注册时间、互动关系、优惠话术共现，把「关系图异常」从描述变成可计算。
4. **配对原图与转码比对（预计 +3 至 +5）**：转发变体需要原图；视频转码需要同源双份素材。
5. **语义相似度（预计 +3 至 +4）**：FlagEmbedding 做模板改写聚类，替代字面重复判定。

全部落地后估算可到 78% 至 85%。要到 90%，还需要把「图文含义冲突」这一类交给多模态模型逐案判断，并且接受这部分延迟从 2 秒上升到 8 秒。

8 口径声明

本报告的 57.14% 只能表述为「在本验收集上的严格通过率」。三条限制必须同时说明：一是参考标签由构造规则生成，与本文实现的规则同源，分数天然偏高，不能当作真实世界鉴真准确率；二是样本自带的资料卡在线上并不总是存在，本文把「检索已命中」当作前提，真实检索的命中率另需测量；三是保留测试片只提升 7 条，说明部分规则对开发片有依赖，跨集泛化仍需验证。

复算脚本：`QA-140-report/scripts/eval_local.mjs`（本地直调流水线，不走 HTTP，可复现）
原始结果：`QA-140-report/data/eval_local.json`